

目 录

1	毕业设计（论文）内容概述	2
1.1	项目来源及开发目的和意义	2
1.2	主要开发任务	3
1.3	本人所承担任务（模块）说明	3
2	已完成的研究工作及成果	4
2.1	预定计划的执行情况	4
2.2	系统评估情况	4
2.3	系统总体设计	6
2.4	系统架构设计	8
2.5	模块交互设计	10
2.6	系统的详细及实现设计	11
3	后期拟完成的研究工作及进度安排	12
3.1	后期拟完成的工作	12
3.2	后期工作的进度安排	13
4	存在的问题与困难	13
5	论文按时完成的可能性	13

一 毕业设计（论文）内容概述

1.1 项目来源及开发目的和意义

本课题来源于面向蛋白质设计任务的多 Agent 系统工程实践需求。随着大语言模型在任务规划、工具调用和复杂流程编排中的能力不断增强，使用自然语言驱动多步骤科研任务已经具备了较强的可行性。在蛋白质设计场景中，这种能力尤其具有吸引力，因为该类任务通常同时涉及序列生成、结构预测、质量评估、候选筛选和结果汇总等多个异构环节，传统流程往往依赖研究人员在不同工具之间进行人工切换、参数调整和结果比对，工作链路长、重复劳动多，而且缺少统一的状态管理和审计机制。如何将大语言模型的规划能力与生物信息工具链的可执行能力结合起来，并通过多 Agent 协作方式把规划、执行、安全审查和总结等异构职责稳定分离，成为本课题的直接出发点。

从现有系统形态来看，通用 LLM Agent 在开放环境中已经能够完成一定程度的工具调用与任务分解，但若直接迁移到蛋白质设计场景，仍然存在若干明显不足。首先，许多代理系统依赖隐式对话状态或单轮推理结果推进任务，缺乏清晰的外显状态表达，一旦执行中断、工具失败或人工需要介入，系统难以准确恢复到可继续运行的上下文。其次，科研工作流往往并非一次规划即可稳定执行到底，局部步骤失败、结果不满足约束、工具输出格式异常等情况都很常见，如果没有结构化的失败恢复机制，系统就容易在错误后陷入无序重试甚至整体崩溃。再次，蛋白质设计涉及安全性、合规性和结果可信度问题，单纯依靠模型自发判断缺乏足够的可解释性，也难以支撑后续的复盘与评估。因此，本课题并不把目标简单设定为“让模型调用更多工具”，而是更强调在复杂科研任务中建立一套可控、可恢复、可审计的智能体执行闭环。

基于上述问题，本课题拟设计并实现一个以多 Agent 协作为核心的蛋白质设计系统，以显式有限状态机作为全局控制骨架，以 Planner、Executor、Safety 和 Summarizer 四类 Agent 作为职责边界，以 ToolKG 和工具适配层作为执行基础，使系统能够围绕候选生成、状态推进、失败恢复和人在环决策形成统一流程。与单一路径执行的传统代理不同，本系统将关键决策节点明确暴露出来，通过候选集、门禁逻辑和待确认状态承载人工监督；在执行阶段通过分层恢复策略将 retry、patch 和 replan 区分为不同层级的控制动作；在结果沉淀阶段进一步通过事件日志、任务快照和报告产物保留执行证据。这一思路的意义在于，它不仅能够提高蛋白质设计任务的自动化程度，也使“多 Agent 驱动”不再停留于模块命名，而是具体落实为职责分明、可控协作的工程结构，为后续实验评估、过程回放和论文写作提供了稳定基础。

从论文选题的角度看，本课题兼具工程实现价值与研究验证价值。一方面，它试图回答“多 Agent 驱动的蛋白质设计系统应如何建立可控执行机制”这一问题，强调角色分工、状态机、人机协同和恢复控制在复杂科研任务中的必要性；另一方面，它也以蛋白质设计这一具有明确工具链和质量约束的应用场景为落点，为后续纵向机制增量实验和横向代理范式比较提供了可实现、可观察的系统载体。因此，本课题并不是对现有模型能力的简单包装，而是围绕科研场景中“如何安全、稳定、可追踪地用好多 Agent 系统”这一核心问题展开的系统性探索。

1.2 主要开发任务

围绕课题目标，中期阶段的主要开发任务可以概括为系统架构落地、关键控制链实现、领域 workflow 接入以及阶段性验证材料整理四个方面。首先，在总体架构层面，需要完成任务对象、执行计划、步骤结果和最终结果等核心数据契约的定义，并在此基础上建立 API 入口、工作流编排模块、日志与快照存储模块之间的协同关系，使系统能够以统一的数据结构驱动规划、执行和汇总全过程。其次，在智能体职责设计方面，需要将 Planner、Executor、Safety 和 Summarizer 的边界落实到实际代码中，避免规划、执行、审核和总结之间出现角色混淆，特别是要确保状态变更只能由工作流控制逻辑推进，执行代理不能绕过决策机制直接修改关键状态。

在核心运行机制方面，本课题需要完成显式 FSM 及其等待状态语义的实现，使任务可以按照创建、规划、等待确认、执行、总结和完成等阶段稳定推进。与此相配套的，是候选集决策与分层恢复机制的落地：系统需要在初始规划、局部修补和再规划等关键节点输出结构化候选，并根据风险、成本和置信度触发自动执行或人工确认；在执行链路中，还需要建立严格的恢复顺序，使单步失败优先进入有限重试，再视情况触发 patch，最后才进入 replan。为了支撑这一过程，项目还需要实现 PendingAction、Decision、EventLog 和 TaskSnapshot 等机制，使等待中的任务能够被审查、被恢复、被回放。

在领域能力接入方面，课题需要将蛋白质设计任务拆解为可执行的多阶段工作流，并逐步完成与 ToolKG、工具适配器和远端服务的衔接。目前系统已经围绕序列探索、结构映射、质量门禁、结构条件精修、多目标打分和恢复控制形成了较为清晰的六阶段组织方式。为了让这些环节真正服务于中期论文写作，还需要进一步整理验证报告、实验设计文档、图示材料和展示路径，形成能够支撑“系统已基本建立工程闭环，但实验比较仍在持续完善”这一阶段结论的证据包。换言之，中期前的任务并不只是完成若干分散功能点，而是要把架构、实现、验证和写作材料整理成一个相互对应的整体。

1.3 本人所承担任务（模块）说明

在本课题的实施过程中，本人承担的工作主要集中在系统总体方案细化、核心工作流实现、控制机制落地以及阶段性材料沉淀四个方面。首先，在系统设计层面，本人围绕多 Agent 架构、显式状态机和六阶段蛋白质设计工作流持续整理设计文档，将任务生命周期、角色职责、数据契约和恢复顺序固化为较为明确的系统约束，为后续实现与验证提供统一依据。其次，在工程实现层面，本人重点参与了工作流主链的搭建，包括任务创建与执行入口、规划结果固化、执行阶段状态推进、等待确认状态处理、人工决策生效以及总结收尾等关键流程的实现，使系统能够从自然语言任务出发，完成规划、执行、恢复和汇总的完整闭环。

在关键机制建设方面，本人重点负责候选集决策、门禁逻辑与失败恢复链路的落地。具体而言，一方面围绕 Plan、PlanPatch 和 Replan 等候选对象组织 Top-K 输出、默认建议和待确认动作，使系统在自动执行与人工审查之间具备明确切换条件；另一方面围绕运行失败、质量门禁和安全阻断等场景，将 retry、patch 和 replan 组织成分层恢复策略，并通过事件日志与任务快照保留恢复过程中的关键证据。这部分工作直接关系到系统是否具备

可控执行能力，也是本课题区别于一般工具调用型代理的重要实现内容。

此外，本人还承担了与中期报告直接相关的材料整理工作，包括验证报告、实验设计文档、项目进度梳理、图示更新以及论文参考资源归档等内容。通过将项目设计、代码实现、GitHub issue 进展和验证结果进行统一整理，可以使论文撰写不再停留于抽象描述，而是能够对应到系统当前已经具备的功能、尚待补齐的实验部分以及下一阶段的推进重点。总体而言，本人承担的模块覆盖了从设计到实现、从运行机制到论文材料的主要链路，核心目标是为课题后续的中期答辩和最终论文撰写建立一套结构清晰、证据完整的基础版本。

二 已完成的研究工作及成果

2.1 预定计划的执行情况

截至中期阶段，本课题的推进顺序整体上遵循了“先完成控制面，再完善 workflow，最后补充实验与论文材料”的主线。前期工作主要集中在 FSM、HITL、PendingAction、Decision、TaskSnapshot 和 EventLog 等系统骨架的落地，为后续真实工具接入和恢复控制建立稳定基础；随后逐步完成 ProteinToolKG、从头设计最小闭环、演示链路、CandidateSet v1、Patch/Replan 分层恢复以及六阶段 workflow 覆盖；进入后期后，工作重点进一步转向数据整理、实验验证、治理复核和论文材料收口。表 2-1 对当前阶段的主要计划完成情况进行汇总。

从目前的完成情况来看，系统主体、关键控制机制和主要工程证据已经形成，能够支撑中期答辩中的系统演示与技术论述；但仍有一部分工作尚未完成，主要集中在外部模型专用训练、横向对比实验、统一评估收口以及论文图表与结论的最终定稿。因此，中期阶段更准确的判断应当是：系统实现已基本成型，实验与评估部分处于阶段性完成状态，后续工作仍然具有明确而集中的推进重点。

当前阶段的工作表明，系统已经具备较强的中期展示支撑能力。任务创建、候选生成、门禁判断、等待态固化、人工决策生效、失败恢复和总结输出等关键链路均已形成闭环，说明本课题已经从方案设计阶段进入到可运行、可验证、可说明的实现阶段。

2.2 系统评估情况

中期阶段的系统评估主要围绕功能正确性、运行可用性、治理可追溯性以及实验验证四个方面展开。就功能正确性而言，当前系统已经完成了从任务输入到结果输出的完整链路验证，能够稳定覆盖自然语言任务解析、候选集门控、执行调度、等待态处理、决策回流和结果汇总等关键环节。就运行可用性而言，系统已经验证了工具适配、远程调用、失败恢复和接口联动等行为，说明其并非停留在静态设计层，而是具备实际运行能力。

在治理与审计方面，系统已经形成由 PendingAction、Decision、EventLog 和 TaskSnapshot 组成的证据链，使关键状态变化、人工确认和恢复行为能够被追溯和解释。这一点对于科研辅助系统尤为重要，因为系统不仅需要“能够完成任务”，还需要“能够说明任务是如何完成的，以及在何处进行了人工干预”。

表 2-1 项目进度及毕业设计（论文）工作计划完成情况表

起始时间	完成时间	计划工作内容	备注（是否已完成）
2025.12.26	2026.01.15	完成 FSM/HITL 重构、PendingAction/Decision/TaskSnapshot/EventLog 等核心对象设计，建立任务状态推进、人工决策与审计记录的基本框架。	已完成
2026.01.14	2026.01.25	完成 ProteinToolKG 最小可用形态，以及从头蛋白质设计最小闭环，初步实现“规划、执行、失败判定、结果汇总”的连续链路。	已完成
2026.02.01	2026.03.08	完成系统演示链路与工具扩展，补齐启动脚本、任务状态展示、PendingAction 决策界面、事件时间线以及远程工具接入能力。	已完成
2026.03.01	2026.03.15	完成 CandidateSet v1、Top-K 候选生成、风险与成本门控、候选校验器，以及六阶段 workflow 前四阶段的关键实现。	已完成
2026.03.01	2026.03.15	完成 Patch/Replan 分层恢复、恢复链可观测性增强、训练数据抽取与质量门禁，并补齐六阶段后两阶段的关键能力。	已完成
2026.03.14	2026.03.15	完成中期实验计划冻结、数据版本冻结、纵向增量实验和治理复核，为中期阶段的系统论证和后续实验推进提供基础。	已完成
2026.03.01	—	外部模型专用训练尚未启动，后续需要在统一数据口径和评估标准下完成训练实施、结果复核和回退策略验证。	未开始
2026.03.14	—	横向对比实验、统一评估结果收口、多工具验收以及论文图表和阶段总结的最终定稿仍需继续推进。	进行中

在实验验证方面，当前已经完成纵向实验方案的组织与阶段性运行，并完成治理复核，说明实验框架、指标口径和证据链已经基本建立。但横向对比实验尚未完成，统一评估结果仍需在后续阶段继续收口；同时，外部模型专用训练尚未正式启动，因此训练效果及其对规划质量的影响暂时还不能作为中期阶段的既有结论。表 2-2 对当前评估工作的阶段性情况进行了归纳。

表 2-2 系统评估工作阶段性情况

评估内容	当前状态	说明
功能闭环验证	已完成	已验证任务创建、候选生成、门禁判断、等待态处理、人工决策、失败恢复和结果汇总等核心链路。
运行可用性验证	已完成	已验证工具适配、远程调用、接口联动与恢复机制，说明系统具备实际运行能力。
治理与审计复核	已完成	已形成 PendingAction、Decision、EventLog、TaskSnapshot 的可追溯证据链。
纵向实验验证	部分完成	已完成实验组织、阶段性运行与治理复核，可用于说明实验框架和工程闭环已建立。
横向对比实验	未完成	基线方案和比较思路已明确，但正式运行和结果整理仍待后续完成。
外部模型训练评估	未开始	外部模型专用训练尚未启动，因此训练效果及相关评估尚未展开。

2.3 系统总体设计

本系统的总体设计目标，是把面向蛋白质设计的复杂科研任务从“依赖人工串联多个工具与脚本”的离散流程，重构为“由显式状态机控制、由多 Agent 分工协作、由工具适配层统一承接执行”的连续系统。围绕这一目标，系统采用了五层组织方式：输入层负责接收自然语言目标与结构化约束；规划与控制层负责根据任务目标、工具知识图谱和治理策略生成候选计划并进行门禁判断；执行与恢复层负责实际调用工具并在失败时触发分层恢复；安全与汇总层负责风险评估和结果汇总；资源层负责沉淀工具元数据、事件日志、快照和最终产物。这样设计的核心原因在于，蛋白质设计任务本身并不是单次模型推理就能完成的线性问题，而是一个需要在规划、执行、检查、修复和人工确认之间反复切换的过程，因此系统必须拥有稳定的控制面和清晰的职责边界。

从角色划分上看，Planner 负责产生结构化候选，而不直接执行工具；Executor 负责串联计划执行、失败检测和恢复触发，但不拥有人工决策权；Safety 负责对输入、步骤和输出进行风险评估，只输出允许、告警或阻断结论；Summarizer 负责将过程性结果整理为可读报告，而不改变控制决策。通过这种划分，系统在工程上避免了“谁都可以决定下一步如何执行”的混乱状态，也为后续测试和审计提供了明确的责任归属。

图 2-1 采用 UML 类图形式，从课题标题所强调的“多 Agent 驱动”出发，对系统的核心协作关系、关键对象和主要依赖进行了进一步抽象。与一般仅强调工具编排的系统不同，本文系统将任务对象、工作流控制器、四类 Agent、工具知识图谱、适配器、待确认动




图 2-1 多 Agent 核心协作类图

作、日志快照和结果对象纳入同一张结构图中：Planner 面向“应该做什么”，Executor 面向“如何把计划执行出来”，Safety 面向“结果是否允许继续推进”，Summarizer 面向“如何把过程结果整理为对人类友好的输出”。这些 Agent 并不是并列运行的松散模块，而是通过统一的 Workflow Runtime 和状态推进机制形成有约束的协作网络。以 UML 类图表达这一关系，有助于将“对象是什么”“谁依赖谁”“哪些对象在运行期被创建和持久化”同时呈现出来，也更符合论文中对系统结构进行规范化表达的要求。




图 2-2 系统总体组件视图

图 2-2 展示了当前系统的总体组件关系。与传统的“单个代理直接调用若干工具”不同，本文系统在接口层之下显式引入了 workflow 控制层与等待态决策层。用户或 API 提交的任务会进入统一的 Workflow Runtime，在此基础上由 Planner 结合 ToolKG、候选打分与门禁逻辑生成 Plan / PlanPatch / Replan 候选，再由 Executor 进入具体执行；一旦触发等待态，系统通过 PendingAction 和 Decision 机制暂停自动推进，并在恢复后继续运行。资源层中的 EventLog、TaskSnapshot 与报告产物则持续记录系统运行证据，使整个执行闭环既能自动完成，也能在需要时被人工回看和解释。这种设计正是本课题在中期阶段已经较为成熟的系统主线。

2.4 系统架构设计

在具体架构层面，系统目前已经形成较为清晰的分层实现。输入层主要由 FastAPI 和任务对象构成，承担用户请求接入、任务创建和基础查询能力；规划层围绕 PlannerAgent 展开，负责从任务目标中抽取意图、结合 ToolKG 选择能力路径，并生成结构化的候选计划；执行层围绕 ExecutorAgent、PlanRunner、PatchRunner 和 StepRunner 展开，承担具体步骤调度、工具调用和失败恢复；安全与汇总层通过 SafetyAgent 和 SummarizerAgent 对执行过程进行风险评估与结果整理；资源层则通过本地存储、日志、快照和输出产物目录对整个系统运行过程进行持久化。五层之间并不是简单的串行调用关系，而是通过统一数据契约、状态迁移和待确认动作保持协同。

图 2-3 给出了一个比详细组件图更易于快速理解的分层架构版本，适合作为论文阅读




图 2-3 系统分层架构概览

和后续答辩展示中的总览图。该图突出展示了系统从表现层、编排层、Agent 层到底层执行与持久化层的分工关系，有助于在较短时间内说明“请求如何进入系统、状态如何被控制、Agent 如何协同、工具如何被调用、证据如何被保存”这五个核心问题。相较于更细粒度的组件关系图，这种分层图更强调架构边界和责任分布，适合在论文中承担“快速建立整体认知”的功能。

表 2-3 系统架构分层及其当前实现形态

架构层次	主要职责	当前实现形态
输入层	接收任务、组织请求、暴露查询与决策接口	以 API 接口和任务服务为主，负责系统入口与任务管理
规划与控制层	任务解析、ToolKG 检索、候选生成、打分与门禁	以 Planner、候选校验和门禁逻辑为主，负责控制面生成与筛选
执行与恢复层	按步骤执行计划、检测失败、触发 patch/replan、恢复执行	以执行器、步骤调度器和恢复控制组件为主，负责运行主链
安全与汇总层	输入/过程/输出风险检查、结果汇总与报告生成	以风险审查和结果整理模块为主，负责约束与输出解释
资源层	工具元数据、事件日志、快照、产物与报告持久化	以工具注册表、日志快照存储和产物目录为主，负责证据沉淀

系统架构中最关键的一点，是数据契约与状态语义被放在与功能实现同等重要的位置。当前系统围绕 ProteinDesignTask、Plan、StepResult、DesignResult、PendingAction 和 Decision 等对象建立了较稳定的契约，这些对象共同承担了“任务如何表示、候选如何交付、执行结果如何回写、人工决策如何生效”的问题。以 Plan 为例，它不仅保存步

骤序列，也通过步骤输入、工具标识和元信息约束执行链如何落地；以 `StepResult` 为例，它不仅记录某一步成功或失败，还保留工具输出、度量指标、失败类型和时间戳，为后续恢复、总结和追溯提供依据；以 `DesignResult` 为例，它将最终序列、结构、得分和报告路径统一封装为面向用户和论文材料的输出对象。这些契约保证了系统运行不是依赖一系列临时变量或松散脚本，而是建立在可被校验、可被持久化的结构化对象之上。

除数据契约外，系统还将执行合法性和候选质量控制前置到了规划阶段。当前实现中，`Planner` 在生成初始 `Plan`、`Patch` 或 `Replan` 候选后，并不会简单地把结果直接交给执行器，而是先通过候选校验和打分逻辑检查工具可用性、输入输出闭包、参数合法性以及恢复容忍策略，再结合风险、成本与置信度决定是否自动放行或进入等待态。也就是说，本系统的核心算法虽然并不是本章的展开重点，但已经明确体现为“候选生成 -> 候选筛选 -> 门禁决策”的受控路径，而不是单次生成后直接执行。这样做的价值在于，一方面可以在执行前过滤掉明显不可用的候选，另一方面也使人工确认的介入具有明确触发条件，而不是依赖临时主观判断。对中期论文而言，这部分机制体现了系统架构的一个重要特点，即规划与执行不是松耦合的前后两个阶段，而是通过契约和门禁逻辑紧密衔接的整体。

2.5 模块交互设计

从任务生命周期的视角观察，当前系统的模块交互已经形成一条完整主链。用户首先通过 API 或界面提交自然语言任务，系统将其封装为统一任务对象，并进入 `CREATED` 与 `PLANNING` 状态。随后，`Planner` 根据任务目标、约束信息与 `ToolKG` 检索结果生成候选计划集合；如果门禁判断认为当前候选存在较高风险、较高成本或较低置信度，则系统会创建 `PendingAction(plan_confirm)`，进入 `WAITING_PLAN_CONFIRM`，由人工从候选集中进行确认；如果满足自动放行条件，则系统会直接固化默认候选并推进到执行态。该过程意味着 `Planner` 并不直接“决定”系统下一步做什么，而是输出候选、默认建议和解释信息，真正的状态推进由 workflow 控制逻辑负责。

进入执行阶段后，`Executor` 会基于当前 `Plan` 逐步调度 `StepRunner` 与工具适配器完成具体步骤执行。若步骤正常完成，结果会被写入上下文并作为后续步骤输入；若步骤失败，系统首先遵循既定的重试策略，重试耗尽或检测到可修复失败类型后，再由 `PatchRunner` 触发局部修复候选生成。如果 `Patch` 候选需要人工确认，则任务进入 `WAITING_PATCH_CONFIRM`；若高风险或局部修复无法成立，则进一步升级到 `Replan` 流程，并在必要时转入再规划确认等待态。在这一过程中，`Executor` 负责发现问题和暂停执行，但不拥有“自行接受某个 `Patch` 或 `Replan`”的权限，这一点保证了执行控制和人工决策之间的边界清晰可见。换言之，系统在交互层面看似是一个可操作、可确认的研究辅助平台，但在控制逻辑上仍有一条清晰的亮点机制主线，即 `retry -> patch -> replan` 与 `HITL` 决策共同组成的分层恢复闭环。

图 2-4 以更紧凑的方式展示了恢复控制与人在环机制之间的关系。可以看到，系统并不会在单步失败后立即进入全局重规划，而是先进行受限重试，再根据情况生成 `Patch` 候选并经过门禁判断；只有在 `Patch` 不可行、高风险或被人工拒绝时，才进一步升级到 `Replan`。这个过程说明，`HITL` 机制并不是游离在系统之外的额外确认步骤，而是和恢复控制共同构成了当前系统最重要的亮点机制之一。相较于复杂的详细时序图，这种机制图更适合在




图 2-4 恢复控制与 HITL 机制概览

中期报告中承担“快速说明控制主线”的作用，也更方便后续直接转化为答辩展示图。

在模块交互闭环中，**Safety** 和 **Summarizer** 也承担着不可替代的作用。**Safety** 并不是执行结束后才进行的一次性检查，而是可以在任务输入、单步结果乃至最终输出阶段参与风险判断，输出允许、告警或阻断结论。一旦出现阻断，系统就会重新进入恢复控制链，而不是继续沿错误路径运行。**Summarizer** 则位于执行和展示之间，将分散在多个步骤中的结果、指标和产物路径整理为统一的 **DesignResult** 与报告文件，使系统输出能够同时服务于用户理解、结果归档和论文材料整理。由此可见，当前系统的模块交互设计并不是围绕“如何完成一次工具调用”展开，而是围绕“如何稳定地完成一项复杂任务”展开的。

2.6 系统的详细及实现设计

在实现层面，当前系统已经形成了较清晰的模块组织。接口层负责处理任务创建、任务查询、待确认动作查询、人工决策提交以及事件流展示等操作；同步运行主链负责串联 **Planner**、**Executor** 与 **Summarizer**，构成最小可用执行闭环。**Planner** 在保留基于 **ToolKG** 的能力路径选择之外，还进一步支持 **plan_top_k**、**patch_top_k** 和 **replan_top_k** 三类候选生成接口，并通过候选打分、默认建议与门禁判断决定系统是自动放行还是进入等待态。这里的算法亮点并未脱离系统实现单独存在，而是直接落在候选对象与评分字段中，例如 **score_breakdown**、**risk_level**、**cost_estimate** 和 **default_recommendation** 等信息都会随着候选一起进入后续控制链。**Executor** 侧则通过计划执行、补丁执行和单步运行等不同粒度的组件拆分执行调度与恢复控制，以避免复杂逻辑堆叠在同一模块中。

从执行控制细节来看，**PlanRunner** 负责维持计划执行的主循环，在必要时将任务从 **PLANNED** 推进到 **RUNNING**，并在执行结束后推进到 **SUMMARIZING**。**PatchRunner** 则承担失败恢复中的关键角色：它先对单步结果进行失败类型判断，再根据情况构造 **Patch** 请求、生成候选集、执行门禁判断，并决定是直接应用自动路径还是进入等待态。对于可自动执行的低风险 **Patch**，系统会经历 **WAITING_PATCH**、**PATCHING** 再回到 **RUNNING**；对于高风险或不适合局部修复的场景，则会升级为 **Replan**。与此同时，**resolve_s6_recovery_action** 等逻辑将恢复控制与六阶段工作流结合起来，使系统的恢复策略不只是通用异常处理，而是与蛋白质设计任务的阶段语义保持一致。换言之，核心算法中的亮点机制在代码层主要表现为三点：一是候选生成与门禁判断始终绑定出现；二是恢复控制遵循从局部到整体的递进顺序；三是再规划默认尽量保留已成功前缀，而不是无差别推翻整条链路。这样的实现方式表明，本系统并不是在发生错误后“临时加一个补丁流程”，而是把这些亮点机制直接嵌入到了正式运行主链中。

等待态与人工决策机制的实现也是当前系统的重要完成成果之一。进入等待态之前，系统会先构造 **PendingAction**，写入候选集、默认建议和解释信息，再通过事件日志与任务

快照将当前上下文完整持久化，之后才允许状态切换到相应的 `WAITING_*`。这样做的直接好处是，即使系统在等待期间中断或重启，也能够基于最近一次快照恢复到一致的待确认场景。待用户提交 `Decision` 后，`decision_apply.py` 会根据动作类型将批准、重规划或取消等操作映射为后续状态推进，同时写入 `WAITING_EXIT` 与 `DECISION_APPLIED` 等结构化事件。这一实现使“人工参与”成为可被审计、可被重放的正式系统行为，而不是仅存在于界面层的外部点击动作。

在可观测与持久化方面，当前系统已经具备较为完整的证据沉淀能力。任务状态变化会同步写入事件日志；在生成新 `Plan`、应用 `Patch`、进入等待态等关键节点，系统会额外写入 `TaskSnapshot`，以保存当前计划版本、已完成步骤索引、相关产物路径以及待确认动作标识。这些数据不仅支持问题排查和过程回放，也直接服务于后续的验证报告和论文写作。结合当前已经完成的全流程功能验证、API 端点验证、真实 `Provider` 可用性验证以及远端 `REST` 工具链接入验证，可以认为系统的详细实现已经超出了“功能演示原型”的范围，开始具备面向实际科研 workflows 继续演进的基础条件。

最后，从当前代码与验证材料的对应关系来看，本课题已经形成了较完整的“设计文档、代码实现、测试验证、报告沉淀”四位一体结构。设计文档给出了状态机、角色边界、候选契约和恢复顺序等系统约束；代码实现将这些约束落实到 API、工作流、适配器和存储模块中；测试与验证报告则进一步证明这些机制并非纸面设计，而是已经能够在实际运行中形成闭环。对于中期论文而言，这种一致性具有重要意义，因为它说明当前章节中的介绍并不是抽象设想，而是与现有项目仓库中的真实实现保持一致的阶段成果。

三 后期拟完成的研究工作及进度安排

3.1 后期拟完成的工作

中期阶段之后，本课题的后续工作将主要围绕实验补齐、训练推进、系统收口和论文定稿四个方面展开。首先，需要继续完成系统效果验证中的缺失部分，其中最核心的任务是补齐横向对比实验。当前系统已经完成了纵向实验框架、阶段性运行和治理复核，但横向对照尚未形成正式结果，因此后续必须在统一实验条件下完成与典型代理范式的对比运行，并对执行成功率、恢复行为、人工介入情况、审计完整性和端到端稳定性等指标进行整理。只有在这一部分补齐之后，论文中的实验章节才能从“阶段性说明”进一步推进到“具有完整比较依据的正式论证”。

其次，需要推进外部模型专用训练及其后续评估工作。当前系统已经完成训练数据抽取、质量门禁和训练方案准备，但外部模型训练本身尚未正式启动，因此后续需要在统一数据口径下完成训练实施、训练结果整理和训练后评估，并进一步验证模型输出是否能够在候选质量、可执行性和恢复稳定性方面形成可解释的提升。与此相关的另一项工作，是继续完善离线评估口径与统一门禁规则，使训练结果、系统运行结果和实验报告之间能够保持一致的评价标准，从而避免出现“模型已训练但无法形成稳定结论”的情况。

再次，在系统实现层面，后续仍需继续完成多工具统一验收、自动化门禁完善以及部分边界场景补样等工作。当前系统主链已经成型，但若支撑最终论文定稿和答辩展示，还需要进一步提高工具接入的一致性、运行稳定性和证据完整性，尤其是在多工具场景下

的统一调用规范、异常处理策略和验收标准方面，需要继续做收口工作。与此同时，已有的图示、日志证据和阶段性报告还需要进一步整理为可直接用于论文插图、实验图表和答辩展示的标准材料。

最后，论文写作本身也将进入由“章节骨架搭建”转向“正式内容收束”的阶段。除继续完善后续章节正文之外，还需要在实验结论、图表索引、语言风格统一和章节衔接方面做进一步整理，使论文从当前的中期报告版本逐步过渡到结构完整、论证闭环清晰的正式论文版本。换言之，后期工作的重点已经不再是扩展大量新的功能点，而是围绕已有系统成果，将实验、训练、评估和论文表达统一到同一条清晰主线之上。

3.2 后期工作的进度安排

从推进顺序上看，后续工作应当按照“先补实验与评估，再推进训练与收口，最后完成论文定稿与答辩准备”的节奏展开。第一阶段的重点是实验补齐与评估收口，即优先完成横向对比实验、统一已有纵向实验与治理复核结果，并同步整理阶段性图表和指标说明。这一阶段的目标不是继续扩展系统范围，而是尽快把当前已经具备的实验框架转化为可直接写入论文的正式结果，使中期之后的工作建立在更稳定的证据基础之上。

第二阶段的重点是完成外部模型专用训练及相关验证，并同步推进多工具统一验收和门禁完善。由于训练尚未启动，这部分工作必须在实验口径基本稳定之后进行，以避免训练输入、评估方式和系统结论之间出现脱节。在这一阶段中，需要一并完成训练结果复核、必要的回退策略验证，以及多工具场景下的运行一致性检查，从而保证后续论文中的“系统实现”“实验评估”和“局限性分析”三部分能够互相对应。

第三阶段的重点是论文与答辩材料的最终定稿。届时需要在已有章节基础上继续完善实验章节、问题分析、结论与展望等内容，并统一图示、表格、术语和章节语言，使全文形成风格一致、逻辑闭环清晰的正式稿。同时，还需要围绕系统总览图、核心机制图、实验表格和阶段性结论准备答辩展示材料，使论文文本与答辩表达能够保持一致。总体而言，后期工作的边界已经较为清楚，剩余任务虽然仍然较多，但主要属于在既有系统和既有框架基础上的补齐、收口与整合，因此具备继续推进并按时完成的现实基础。

四 存在的问题与困难

本节建议如实陈述当前阶段的限制与风险，不宜回避未完成项。可以结合项目现状重点说明：

- 横向对比实验尚未完成；
- 离线门禁仍存在未达标指标；
- 部分真实远端工具链受外部平台条件限制；
- 主实验中的 WAITING 决策样本仍需补充。

五 论文按时完成的可能性

本节建议从以下方面给出按时完成论文的判断依据：

- 系统主体架构与实现已经完成；
- 中期模板、章节骨架和参考资料已经整理；
- 关键验证报告与展示材料已经具备；
- 剩余工作主要集中在实验补齐与写作收尾，边界清晰。

建议在结尾明确说明：虽然仍有横向实验和门禁收尾工作，但整体项目已经具备继续推进到论文定稿阶段的基础。